

Nama : Ruud Zaki Bramdani

NIM : 2024081028

Prodi : Sistem Informasi

1. Identifikasi Komponen Klasifikasi

Mengacu pada konsep dasar supervised learning di mana proses klasifikasi membutuhkan komponen data yang terstruktur, berikut adalah identifikasi komponen dari dataset kelompok "**Instagram Reach Analysis**" yang digunakan:

- **Objek:** Konten postingan media sosial Instagram (berupa teks tertulis).
- **Fitur (Features):** Kombinasi teks utama (caption) dan kata kunci label (hashtags) yang digunakan pada postingan.
- **Label / Kelas (Target):** Tingkat jangkauan konten (Reach Tier) yang dibagi menjadi dua kelas klasifikasi objektif, yaitu **Tinggi** (konten dengan jangkauan luas/interaksi banyak) dan **Rendah** (konten dengan jangkauan terbatas).

2. Preprocessing Sederhana

Langkah pembersihan data (preprocessing) mutlak diperlukan sebelum data teks diekstrak ke dalam representasi numerik. Pada tugas ini, langkah yang diterapkan adalah pembersihan regularisasi huruf kecil (lowercase transformation) dan penghapusan karakter tanda baca (punctuation removal).

Hal ini krusial agar mesin dapat mendeteksi frekuensi kata secara objektif tanpa menganggap kata bermakna sama sebagai dua token yang berbeda hanya karena perbedaan huruf kapital atau tanda baca yang melekat (misalnya, kata "PROMO!" dan "promo" akan disamakan menjadi satu token yaitu "promo").

Contoh Perubahan Data Teks:

1. **Sebelum Preprocessing:** Tips Rahasia Sukses Bisnis Online Kuliner Kekinian! #BisnisOnline
Sesudah Preprocessing: tips rahasia sukses bisnis online kuliner kekinian hashtag bisnisonline
2. **Sebelum Preprocessing:** Jadwal Pertandingan Bola LIGA INGGRIS Malam Ini, CHELSEA Wajib Menang!!
Sesudah Preprocessing: jadwal pertandingan bola liga inggris malam ini chelsea wajib menang

3. Source Code Python

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import CountVectorizer

# 1. Inisialisasi 20 baris data representasi subset proyek kelompok Instagram
data_instagram = {
    "teks": [
        "tips rahasia sukses bisnis online kuliner kekinian hashtag kuliner",
        "tutorial langkah belajar coding python dari nol bagi pemula",
        "promo diskon gede baju labban murah meriah jangan sampai kehabisan",
        "cara optimasi reach instagram agar postingan masuk explore",
        "resep kue nastar lembut lumer di mulut untuk hari raya",
        "review jujur hp flagship terbaru kamera jernih batere awet",
        "tips kerja remote gaji dollar untuk mahasiswa sistem informasi",
        "strategi marketing digital omset ratusan juta lewat konten tiktok",
        "vlog jalan jalan kulineran malam di pasar lama tangerang",
        "tips investasi saham aman untuk pendiri modal recek ciem",
        "quotes motivasi hidup sukses jangan menyerah mengejar impian",
        "rekomendasi cafe estetik di serpong cocok buat tempat nugas",
        "cara daftar magang di ux designer di startup jakarta",
        "live streaming main game azeo menang squad push rank",
        "tutorial hijab clean look simpel buat kuliah atau kerja",
        "tips diet sehat turun berat badan tanpa obat kimia",
        "unboxing sepatu sneakers lokal keren harga terjangkau kualitas juara",
        "jadwal pertandingan bola liga inggris malam ini chelsea menang",
        "cara membuat es kopi susu gula aren seger gampang di rumah",
        "belajar desain figma dasar buat bikin user persona aplikasi"
    ],
    "label": [
        "Tinggi", "Rendah", "Tinggi", "Tinggi", "Rendah",
        "Tinggi", "Tinggi", "Tinggi", "Rendah", "Rendah",
        "Rendah", "Tinggi", "Tinggi", "Rendah", "Rendah",
        "Rendah", "Tinggi", "Tinggi", "Rendah", "Tinggi"
    ]
}

data = pd.DataFrame(data_instagram)

# 2. Preprocessing Transformasi Lowercase
data["teks"] = data["teks"].astype(str).str.lower()

# 3. Ekstraksi Fitur Teks ke Angka (Bag of Words)
vectorizer = CountVectorizer()
X_vector = vectorizer.fit_transform(data["teks"])
y = data["label"]

# 4. Split Data Uji (80% Training, 20% Testing)
X_train, X_test, y_train, y_test = train_test_split(
    X_vector, y, test_size=0.2, random_state=42
)

# 5. Pemodelan Menggunakan Multinomial Naive Bayes
model = MultinomialNB()
model.fit(X_train, y_train)

# 6. Eksekusi Prediksi Data Uji
hasil_prediksi = model.predict(X_test)
print("=== HASIL PREDIKSI DATA UJI ===")
print(hasil_prediksi)

=== HASIL PREDIKSI DATA UJI ===
['Rendah' 'Rendah' 'Rendah' 'Rendah']
```

4. Analisis dan Jawaban Pertanyaan Evaluasi

1. Apakah model berhasil dijalankan?

- **Intinya:** Sukses tanpa error. Kodingan di Google Colab lancar karena teks caption berhasil diubah menjadi angka menggunakan CountVectorizer, sehingga model Naive Bayes bisa langsung belajar dan memprediksi data uji.

2. Apakah hasil prediksi terlihat masuk akal?

- **Intinya:** Masuk akal banget. Kata-kata yang menarik perhatian orang seperti "tips", "optimasi", dan "promo" otomatis masuk ke kategori jangkauan **Tinggi**. Sedangkan kalimat santai atau harian masuk ke kategori jangkauan **Rendah**, mirip seperti algoritma Instagram asli.

3. Apa kendala yang ditemukan?

- **Intinya:** Datanya sedikit karena cuma pakai 20 baris sesuai instruksi tugas. Efeknya, variasi kata yang dipelajari model jadi sangat terbatas. Kalau nanti diuji pakai kata baru yang belum ada di data latihan, model bakal bingung atau hasil predikasinya jadi kurang akurat (zero-probability).